# Deep-Learning-Modell als Microservice

Entwicklung einer RESTful Web-API für ein Deep-Learning-Modell

### Über mich



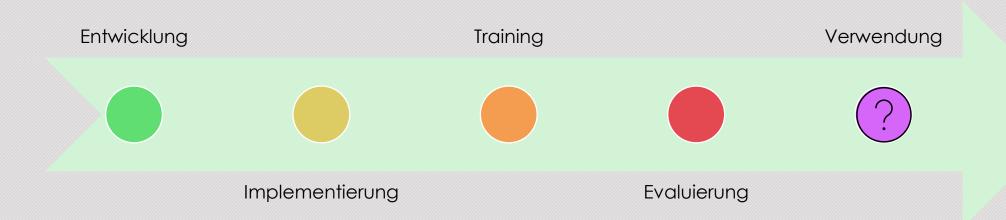
- ITS Master absolviert (2020)
- Software Entwicklung
- Data Scientist bei Symptoma GmbH
  - Fokus im Bereich NLP
  - Gerne mal vorbeischauen unter <a href="https://www.symptoma.at/">https://www.symptoma.at/</a>



## Agenda

- Problem "Deployment"
- REST API
- Praktisches Beispiel
  - 1. Unser Modell
  - 2. API mit Flask
  - 3. API Dokumentation
  - 4. Unser Modell als API
  - 5. Docker
  - 6. Google Cloud

# Problem "Deployment"



# Problem "Deployment"

#### Verwendung

Download

git clone https://github.com/abc/dl-model.git

EXAMPLE

• "Predict"



# Problem "Deployment"

#### Verwendung

Download

git clone https://github.com/abc/dl-model.git

EXAMPLE

• "Predict"

python train.py -task abs -mode validate -encoder bert -batch\_size
3000 -test\_batch\_size 500 -data\_path ./data -log\_file
./logs/model2 -model\_path ./model/checkpoint\_21\_2021-0130T10:47:24.404933.pt -sep\_optim true -use\_interval true visible\_gpus 1 -max\_pos 512 -min\_length 20 -max\_length 100 -alpha
0.9 -result\_path ./logs/result -temp\_dir ./temp -large true use\_bert\_emb true -block\_trigram true
EXAMPLE

#### Was ist eine REST-API?

- REpresentational State Transfer
  - ...ist ein Architekturstil für die Kommunikation verteilter Systeme
  - ...wird meist per HTTP(S) realisiert
- Application Programming Interface
  - ...ist eine Programmierschnittstelle

[1]

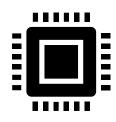
#### Was ist eine REST-API?



# Praktisches Beispiel

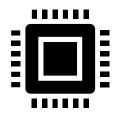
NLP-Modell als Microservice mit REST API

#### NLP-Modell



- Unser Modell: GPT-2 [2]
- NLP Modell für Text-Generierung
- Framework Transformers

#### NLP-Modell





```
from transformers import pipeline, AutoTokenizer, AutoModelForCausalLM, AutoConfig
import torch

model_str = "gpt2"
device = 0 if torch.cuda.is_available() else -1
generate_pipe = pipeline("text-generation", model=model_str, tokenizer=model_str,
device=device)

if __name__ == '__main__':
    # Call this file with: python train.py "This is the text I want to be continued"
    from codecs import decode
    import sys

input_text = decode(sys.argv[1], 'unicode_escape')
    out = generate_pipe(input_text)
    print(out[0]['generated_text'])
EXAMPLE
```

#### API mit Flask



- <u>Flask</u> ist ein Web-Framework für Python
- Beispiel für eine minimale Applikation:

```
from flask import Flask
app = Flask(__name__)

@app.route('/')
def hello_world():
    return 'Hello, World!'
EXAMPLE
```

[3]

#### API mit Flask



\$ export FLASK\_APP=src/service.py

- \$ flask run
- \* Serving Flask app "src/service.py"
- \* Environment: production WARNING: This is a development server. Do not use it in a production deployment. Use a production WSGI server instead.
- \* Debug mode: off
- \* Running on http://127.0.0.1:5000/ (Press CTRL+C to quit)

**EXAMPLE** 

\$ curl -s http://localhost:5000
Hello, World!

EXAMPLE

#### API Dokumentation



- <u>Flask-RESTX</u> ist eine Erweiterung für Flask
- Hilft bei der Erstellung einer RESTful API
- Stellt Werkzeuge zu Verfügung, um eine API zu beschreiben/dokumentieren
- (Ist ein Community "Fork" von Flask-RESTPlus)

[4]

#### API Dokumentation



```
from flask import Flask
from flask_restx import Resource, Api

app = Flask(__name__)
api = Api(app)

@api.route('/hello')
class HelloWorld(Resource):
    def get(self):
        return 'Hello, World!'

EXAMPLE
```

#### API Dokumentation



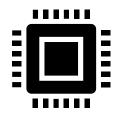
```
from flask import Flask
from flask_restx import Resource, Api

app = Flask(__name__)
api = Api(app)

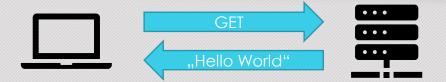
@api.route('/hello')
class HelloWorld(Resource):
    def get(self):
        return 'Hello, World!' EXAMPLE
```

```
O localhost:5000
                                                                  lii\ 🗈 😉 🚾 🥺 🐠 🛙 👬
[ Base URL: / ]
http://localhost:5000/swagger.json
                                                                                              >
default Default namespace
```

#### Unser Modell als API

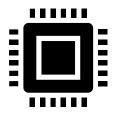


• "Hello World" API:



Text-Generation API:

#### Unser Modell als API

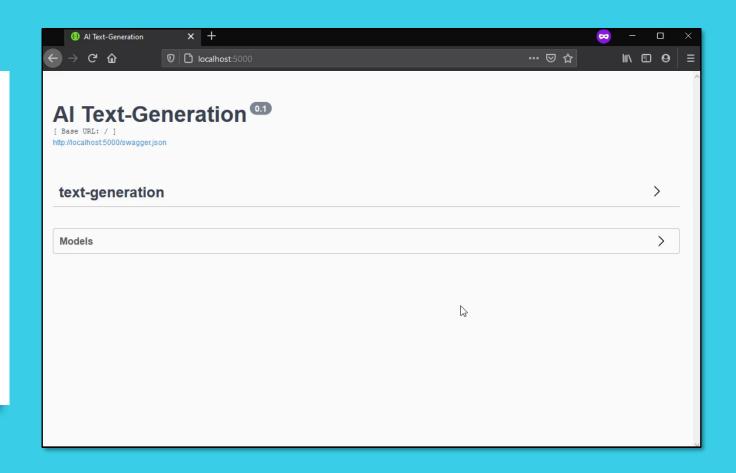


```
from flask import Flask, request
from flask restx import Resource, Api, fields
app = Flask( name )
api = Api(app, version="0.1", title="AI Text-Generation")
ns = api.namespace("text-generation")
# Swagger defs
generation input def = api.model("Text Generation Input", {
    'text': fields.String(required=True, description="Input prompt",
                         help="Text cannot be blank.", example="Artificial Intelligence is a")
})
... # Code for loading model
@ns.route('/generate')
class Generation(Resource):
   @ns.expect(generation input def)
   def post(self):
        input_text = request.json['text']
        ... # model predict code
        return {'input': input_text, 'generated': generated_text}
                                                                                                    EXAMPLE
```

Rafael Weingartner-Ortner | Symptoma GmbH

09.02.2021

# Unser Modell als API



4



[Artificial Intelligence is a] popular technology that enables robots to predict what human beings can do by analyzing their body language and facial expressions.

GPT-2



- Virtualisierungssoftware
- Anwendungen können in Container isoliert werden (Image)
- Docker Hub ermöglicht die Verteilung von Images

[5]

#### Docker und GPUs



#### NVIDIA Container Toolkit

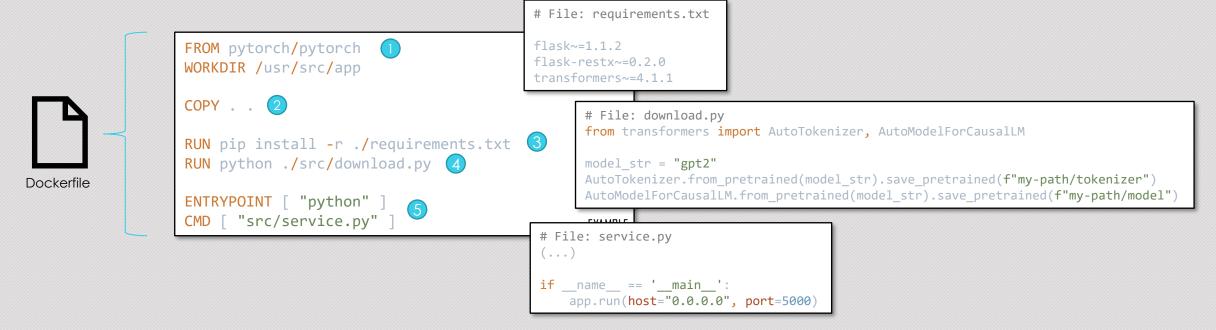
• ermöglicht die Ausführung von GPU-beschleunigten Containern

docker run --gpus all <your-container>

docker run --gpus device=1 <your-container>

# API Docker





Rafael Weingartner-Ortner | Symptoma GmbH

# API ∠→ Docker



1. Image bauen

docker build -t <your\_username>/my-repo .

2. Image verteilen

docker push <your\_username>/my-repo

3. Auf gewünschtem System

docker pull <your\_username>/my-repo
docker run -p 80:5000 <your\_username>/my-repo



6

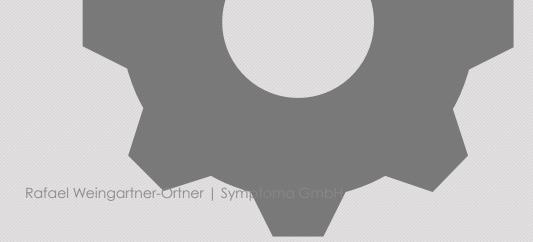
- Infrastructure as a Service (IaaS)
- Compute Engine
  - VM Instanzen erstellen
  - Selbst konfigurieren (installieren aller Treiber etc.)
  - Vorgefertigte Deep Learning Instanzen
- Al Platform
  - Tools für vollständigen ML Lebenszyklus
- 300\$ Startguthaben

[6]

- 1. GCP Instanz erstellen
- 2. Über SSH einloggen
- 3. Docker Image pullen und starten



# API Live-Demo



# GitHub Projekt



Source Code:

https://github.com/RafaelWO/NLP-Microservice

• Docker Image:

https://hub.docker.com/repository/docker/rafaelwo/nlp-ms

#### Weiterführende Themen

- Flask Production Deployment: <u>https://flask.palletsprojects.com/en/1.1.x/deploying/#deployment</u>
- Flask Einfache Authentication via API-Key: <a href="https://blog.ruanbekker.com/blog/2018/06/01/add-a-authentication-header-to-your-python-flask-app/">https://blog.ruanbekker.com/blog/2018/06/01/add-a-authentication-header-to-your-python-flask-app/</a>
- PyTorch Modell mit Flask: <u>https://pytorch.org/tutorials/intermediate/flask\_rest\_api\_tutorials/intermediate/flask\_rest\_api\_tutorials.html</u>

#### Weiterführende Themen

 Keras Modell mit Flask: <u>https://blog.keras.io/building-a-simple-keras-deep-learning-rest-api.html</u>

#### Referenzen

[1] https://www.cloudcomputing-insider.de/was-ist-eine-rest-api-a-611116/
 [2] Radford, Alec, et al. "Language models are unsupervised multitask learners." OpenAl blog 1.8 (2019): 9. (link)
 [3] https://flask.palletsprojects.com/en/1.1.x/
 [4] https://flask-restx.readthedocs.io/en/latest/
 [5] https://docs.docker.com/
 [6] https://cloud.google.com/, https://cloud.google.com/ai-platform